



پروژه درس – سال تحصیلی ۱۴۰۴

طبقه‌بندی انواع سرطان با استفاده از داده‌های بیان ژن RNA-Seq و یادگیری ماشین

Machine Learning Approach to Identify Significant Genes and Classify Cancer Types from RNA-Seq Data

RNA-SEQ · ML · BIOINFORMATICS

5 CANCER CLASSES · 20,531 GENES

ارائه‌دهنده:	مجتبی ریاحی
نام درس:	ژنومیک محاسباتی
استاد درس:	دکتر قنبری
سال:	۲۰۲۵

چرا طبقه‌بندی سرطان با RNA-Seq؟

سرطان یکی از مهم‌ترین علل مرگ‌ومیر در جهان است و تشخیص سریع و دقیق آن نقش حیاتی در موفقیت درمان دارد. فناوری RNA-Seq امکان اندازه‌گیری میزان بیان هزاران ژن را به‌طور همزمان فراهم کرده است.

◆ سرطان یکی از مهم‌ترین علل مرگ‌ومیر در جهان است

◆ تشخیص سریع و دقیق نقش حیاتی در درمان دارد

◆ فناوری RNA-Seq امکان اندازه‌گیری میزان بیان هزاران ژن را فراهم می‌کند

◆ الگوی بیان ژن می‌تواند نوع سرطان را مشخص کند

~10 میلیون

مرگ سالانه ناشی از سرطان (2022)



20,531

ژن در هر نمونه RNA-Seq



5 نوع

سرطان قابل طبقه‌بندی



چالش‌های داده‌های بیان ژن

چرا طبقه‌بندی RNA-Seq دشوار است؟



نمونه محدود^{CH-Q2}

تعداد نمونه نسبتاً کم (۸۰۱ نمونه) نسبت به تعداد ژن‌ها که خطر Overfitting را افزایش می‌دهد.



ابعاد بالا^{CH-Q1}

تعداد بسیار زیاد ویژگی‌ها (بیش از ۲۰ هزار ژن) که تحلیل و انتخاب ویژگی را پیچیده می‌کند.



خطر Overfitting^{CH-Q4}

نسبت بالای ویژگی به نمونه، احتمال بیش‌برازش مدل‌های یادگیری ماشین را بالا می‌برد.



همبستگی ژن‌ها^{CH-Q3}

همبستگی بالا بین ژن‌ها موجب Multicollinearity و کاهش پایداری مدل می‌شود.

هدف پژوهش 03

اهداف مطالعه

معیار موفقیت 

۹۹.۸۷%

بالاترین دقت به دست آمده با SVM در 5-Fold Cross Validation

قابلیت تفسیر

پایداری

دقت

1 طبقه‌بندی ۵ نوع سرطان با استفاده از داده‌های RNA-Seq

BRCA, KIRC, COAD, LUAD, PRAD

2 شناسایی ژن‌های مهم و اثرگذار (بیومارکرها)

کاهش از ۲۰۵۳۱ ژن به مجموعه‌ای کوچک و تفسیرپذیر

3 مقایسه چند الگوریتم یادگیری ماشین

هشت مدل طبقه‌بندی شامل RF، ANN، KNN، SVM و غیره

4 انتخاب بهترین مدل طبقه‌بندی

بر اساس دقت و پایداری در Cross-Validation

معرفی داده‌ها 04

داده‌های RNA-Seq مورد استفاده

مشخصات کلی

UCI / TCGA (PANCAN)

منبع داده:

Illumina HiSeq

پلتفرم:

۸۰۱ نمونه

تعداد نمونه‌ها:

20,531 ژن

تعداد ژن‌ها:

۵ نوع سرطان

تعداد کلاس‌ها:

انواع سرطان


PRAD — پروستات

LUAD — ریه

COAD — کولون

KIRC — کلیه

BRCA — سینه



شکل ۱ — فراوانی هر نوع سرطان در مجموعه داده PANCAN (منبع: مقاله)

کاهش ابعاد با روش‌های منظم‌سازی

برای کاهش ابعاد داده‌های RNA-Seq و رفع خطر Overfitting، از سه روش انتخاب ویژگی مکمل هم استفاده شد:



Lasso Regression L1

جریمه L1 – برخی ضرایب را دقیقاً به صفر می‌رساند و انتخاب ویژگی خودکار انجام می‌دهد. مناسب داده‌های پربعد ژنومی.




Ridge Regression L2

جریمه L2 – ضرایب بزرگ را تنبیه می‌کند و Multicollinearity را کاهش می‌دهد. پایداری مدل را بالا می‌برد.



Random Forest Importance RF

اهمیت ویژگی بر اساس کاهش ناخالصی Gini در درختان جنگل. شناسایی ژن‌های اثرگذار.




شکل ۲ – پایپ‌لاین تحلیل: از داده خام تا طبقه‌بندی (منبع: مقاله)

از ۲۰,۵۳۱ ژن به ۱۰۶ ژن کلیدی

مراحل کاهش ویژگی‌ها

- 1 انتخاب ۲۵۰ ژن برتر با Ridge و Lasso
شناسایی ژن‌های با بیشترین اهمیت توسط هر روش
- 2 بررسی همپوشانی با نتایج Random Forest
اشتراک‌گیری با ۲۵۰ ژن برتر RF
- 3 انتخاب ۱۰۶ ژن مشترک
تنها ژن‌هایی که حداقل توسط دو روش انتخاب شده‌اند
- 4 استفاده از این ۱۰۶ ژن برای آموزش مدل‌ها
مجموعه نهایی ویژگی‌ها برای همه الگوریتم‌ها

نتیجه: مجموعه داده نهایی شامل ۸۰۱ نمونه × ۱۰۶ ژن × ۵ کلاس سرطان ✓



شکل ۴ – (A) ژن برتر ۳۰ (B) Ridge ژن برتر (C) Lasso ژن‌های مشترک (منبع: مقاله)

هشت مدل یادگیری ماشین بررسی شده

عملکرد هشت طبقه‌بندهای متفاوت از خانواده‌های یادگیری ماشین روی مجموعه ۱۰۶ ژن ارزیابی شد:



Random Forest

جنگل تصادفی



ANN

شبکه عصبی مصنوعی



KNN

k-نزدیک‌ترین همسایه



SVM

ماشین بردار پشتیبان



QDA

تحلیل تفکیک‌کننده درجه دوم



Naïve Bayes

بیز ساده



AdaBoost

بسته‌بندی تطبیقی



Decision Tree

درخت تصمیم

هر مدل با همان مجموعه ۱۰۶ ژن آموزش داده شد تا مقایسه منصفانه‌ای فراهم شود.

استراتژی ارزیابی و اعتبارسنجی

دو رویکرد اعتبارسنجی

معیارهای ارزیابی

Error Rate

نسبت پیش‌بینی‌های نادرست

دقت (Accuracy)

نسبت پیش‌بینی‌های درست

Confusion Matrix

ماتریس درهم‌ریختگی برای تحلیل هر کلاس

Precision / Recall

دقت و فراخوانی به‌علاوه F1 Score

🏆 معیار اصلی انتخاب: بالاترین Accuracy در Fold CV-5

Split Validation


تقسیم 70٪ آموزش / 30٪ آزمون. ارزیابی سریع و اولیه عملکرد مدل.

Fold Cross-Validation-5

داده به 5 بخش مساوی تقسیم می‌شود؛ هر بار یک بخش به عنوان آزمون و چهار بخش به عنوان آموزش. کاهش Overfitting و افزایش پایداری.

SVM – پایدارترین و دقیق‌ترین مدل

دقت در 5-Fold Cross-Validation



شکل ۸ – مقایسه عملکرد مدل‌ها در 5-Fold Cross-Validation و Split (منبع: مقاله)

۹۹.۸۷%

SVM

بهترین عملکرد

۹۹.۷۵%

KNN

نزدیک به SVM

۹۹.۵۱%

Random Forest

مدل تولیفی قوی

🏆 نتیجه: SVM پایدارترین و دقیق‌ترین مدل بود – Error Rate تنها ۰.۱۳%

دستاوردهای پژوهش



۵ کلاس

طبقه‌بندی موفق

طبقه‌بندی موفق ۵ نوع سرطان (BRCA, KIRC, COAD, LUAD, PRAD) با دقت ۹۹.۸۷٪.



۱۰۶ → ۲۰۵۳۱

کاهش ابعاد

کاهش موفق ابعاد از ۲۰,۵۳۱ ژن به ۱۰۶ ژن کلیدی با Ridge، Lasso و Random Forest.



SVM

کاربرد بالینی

کاربرد SVM در بهبود تشخیص خودکار سرطان و پشتیبانی از تصمیم‌گیری درمانی.



۱۰۶ ژن

بیومارکر بالقوه

شناسایی ۱۰۶ ژن مهم به‌عنوان بیومارکر بالقوه برای تشخیص مولکولی سرطان.

محدودیت‌های پژوهش

با وجود نتایج امیدوارکننده، این مطالعه محدودیت‌هایی دارد که در مطالعات بعدی باید مورد توجه قرار گیرند:

۰۱ کمبود اطلاعات زیستی (Metadata)

مجموعه داده فاقد نام و توصیف ژن‌ها بود. این موضوع شناسایی و درک عملکرد زیستی ژن‌های انتخاب‌شده را دشوار می‌کند و تفسیر بالینی بیومارکرها را محدود می‌سازد.

۰۲ محدود بودن داده به یک منبع

تمام نمونه‌ها از پایگاه TCGA و پلتفرم Illumina HiSeq گردآوری شده‌اند. تنوع کم منابع ممکن است قابلیت تعمیم مدل به داده‌های سایر مراکز یا پلتفرم‌ها را محدود کند.

۰۳ نیاز به اعتبارسنجی روی داده‌های بیشتر

برای تأیید پایداری نتایج، نیاز است مدل‌ها روی مجموعه داده‌های مستقل و بزرگ‌تر اعتبارسنجی شوند. اعتبارسنجی اولیه روی CuMiDa انجام شد اما هنوز کافی نیست.

کار آینده: جمع‌آوری داده‌های چندمرکزی + استخراج Metadata + اعتبارسنجی بیولوژیک بیومارکرها ↗